{EPITECH} MBA Rush 4

SEGMENTATION DES UTILISATEURS

Combien, plutôt que comment : ce que l'usage d'Instagram dit du bien-être_



Audit des données, exploration, modèle et segmentation — et ce que nous refusons d'affirmer

Présentation à la direction Instagram · Groupe Insta Innov

01 L'anonymisation native écarte les contraintes réglementaires

Hors RGPD

Anonymisation totale et irréversible. Absence d'identifiants directs ou indirects. Le règlement ne s'applique pas.

Mineurs

Utilisateurs identifiés sous le seuil légal de leur pays (13-14 ans) lors de la création de leur compte. Profils à vérifier.

Cas particulier

Mineurs australiens de moins de 16 ans identifiés en 2026. Alerte liée au durcissement récent de la législation locale.

Cas médical

Aucune obligation d'hébergement de données de santé (HDS). L'étude est purement statistique et sans visée de soin.

Ce que nous recommandons : Signaler les **227 profils de mineurs en anomalie d'âge** dans le contrôle qualité, sans bloquer leur analyse puisque le fichier reste 100% anonyme.

Ce que nous refusons de faire : Commercialiser, revendre ou exploiter ces indicateurs de bien-être à des fins de ciblage publicitaire, par respect éthique pour le panel initial (*"wellness study"*).

02

UNE DÉMARCHE

En cinq étapes, avec des critères fixés avant les résultats

1 **Auditer**

Deux extraits, une décision par champ

2 **Explorer**

Liens usage ↔ stress, bonheur, sommeil

3 **Construire**

10 variables d'usage, un score de bien-être

4 **Modéliser**

Prédiction vs temps seul ; KMeans vs seuils

5 **Évaluer**

Critères, limites, protection des données

Nos six critères de réussite

Assignable : tout utilisateur se classe avec les seuls champs connus pour tous

Distinct : segments assez grands, non triviaux

Interprétable : peu de variables, noms clairs pour le produit

Stable : deux moitiés des données donnent les mêmes segments

Incrémental : apporte plus que le simple temps passé

Sûr juridiquement : aucune donnée de santé en entrée, pas de ciblage des mineurs, aucune cellule < 50

03

DEUX EXTRAITS PRESQUE IDENTIQUES

Un choix champ par champ

6 / 58

colonnes divergent entre les deux extraits, sur les mêmes 200 000 utilisateurs

0,0000

écart des corrélations clés entre A et B : le choix ne change aucune conclusion

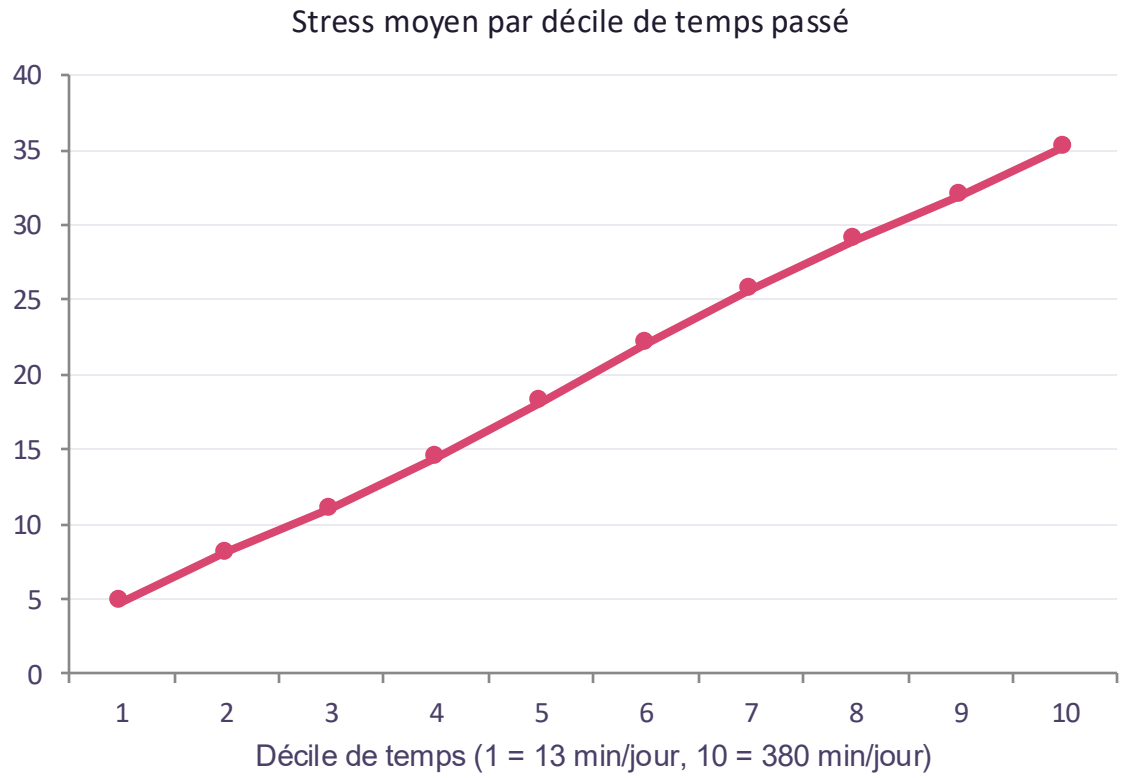
Champ	Source	Pourquoi
Emploi, situation familiale, enfants	B	A contient des mineurs mariés, parents ou à 40 h de travail
Niveau d'études	B harmonisé	Libellés en double à normaliser
Année de création du compte	A	B : 3 724 comptes créés après la dernière connexion
Heures de travail	Écarté	Incohérent dans A, nul dans B, sans pouvoir explicatif
Comportement et bien-être	A = B	Identiques dans les deux extraits

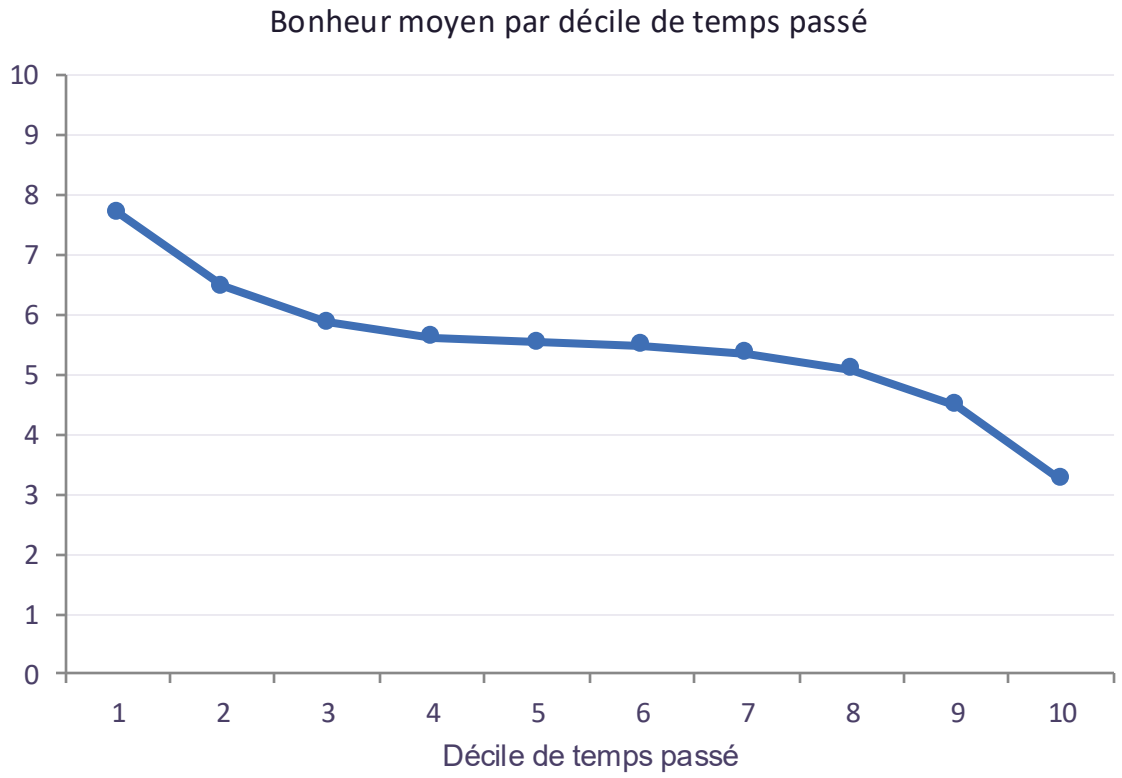
Nettoyage minimal : 3 colonnes retirées (constante, quasi constante, incohérente), 10 768 utilisateurs à 5,0 min/jour gardés mais signalés. Aucune ligne supprimée.

04

CONSTAT

Plus de temps sur l'appli, plus de stress, moins de bonheur



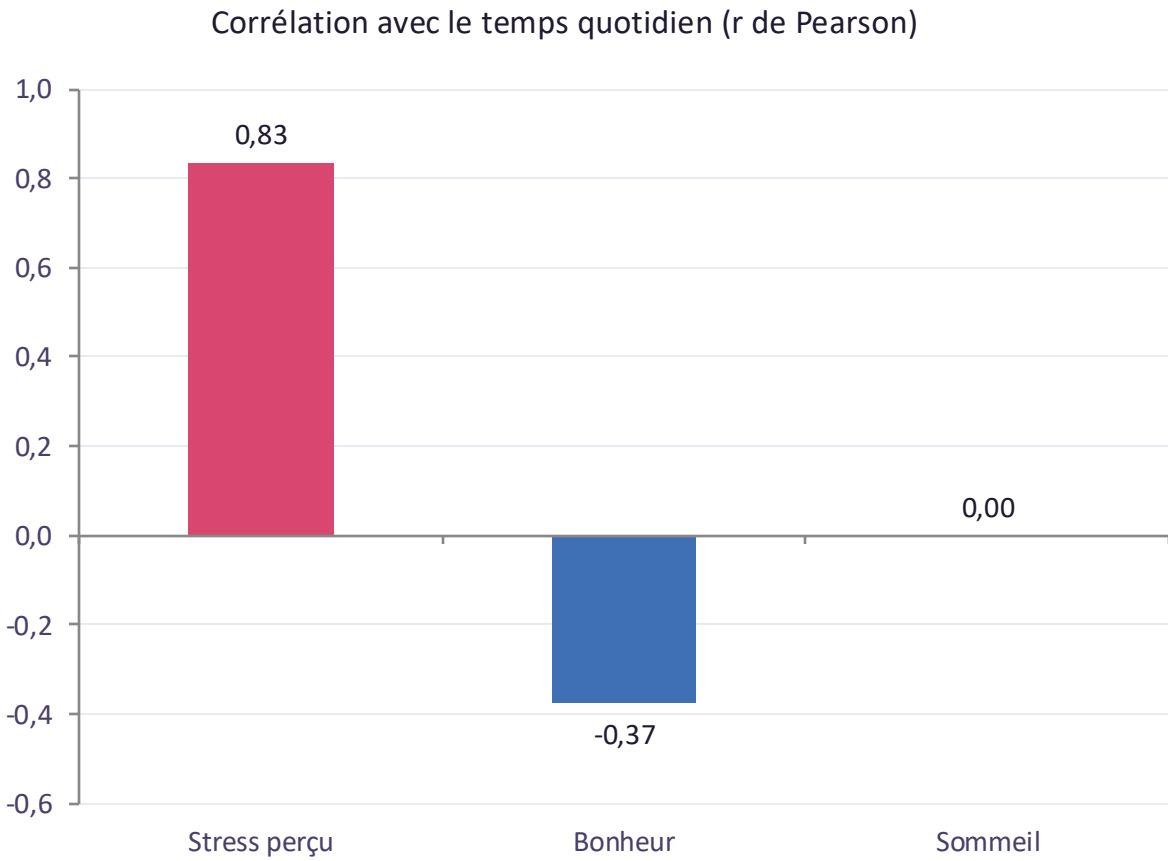


Stress : de 4,8 à 35,3, une hausse régulière (r = 0,83). **Bonheur :** de 7,7 à 3,2, la chute se concentre aux extrêmes (r = −0,37).

05

CONSTAT

Des liens nuls, aussi importants que les liens forts



Sommeil

7 h en moyenne par nuit dans les dix déciles de temps : aucun lien avec l'usage ($|r| \leq 0{,}003$).

Stress et bonheur

Indépendants entre eux ($r = -0{,}002$) : une propriété du générateur synthétique, pas un fait psychologique.

Profil et mode de vie

Âge, genre, pays, revenu, études : $\eta^2 = 0{,}000$ sur le bien-être. Segmenter sur ces champs serait du bruit.

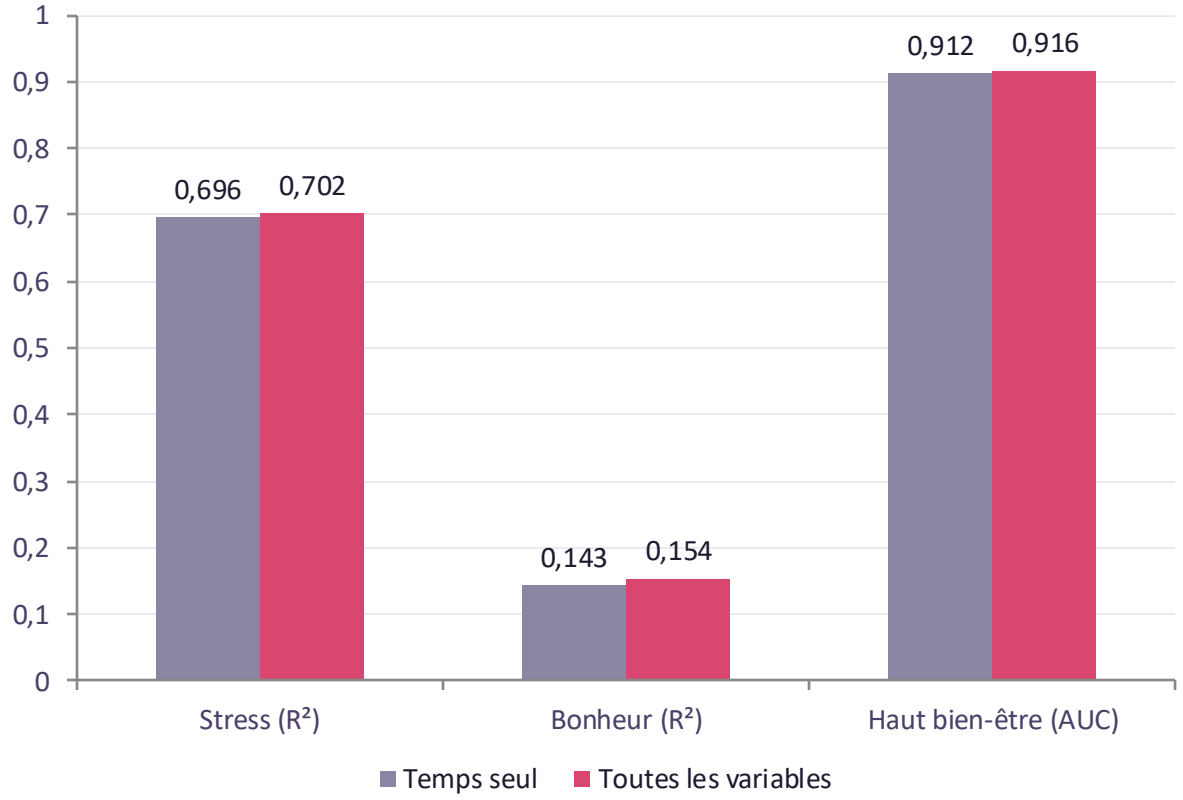
Conséquence : nous ne pouvons pas dire « Instagram n'affecte pas le sommeil », seulement « ces données ne montrent aucun lien ».

06

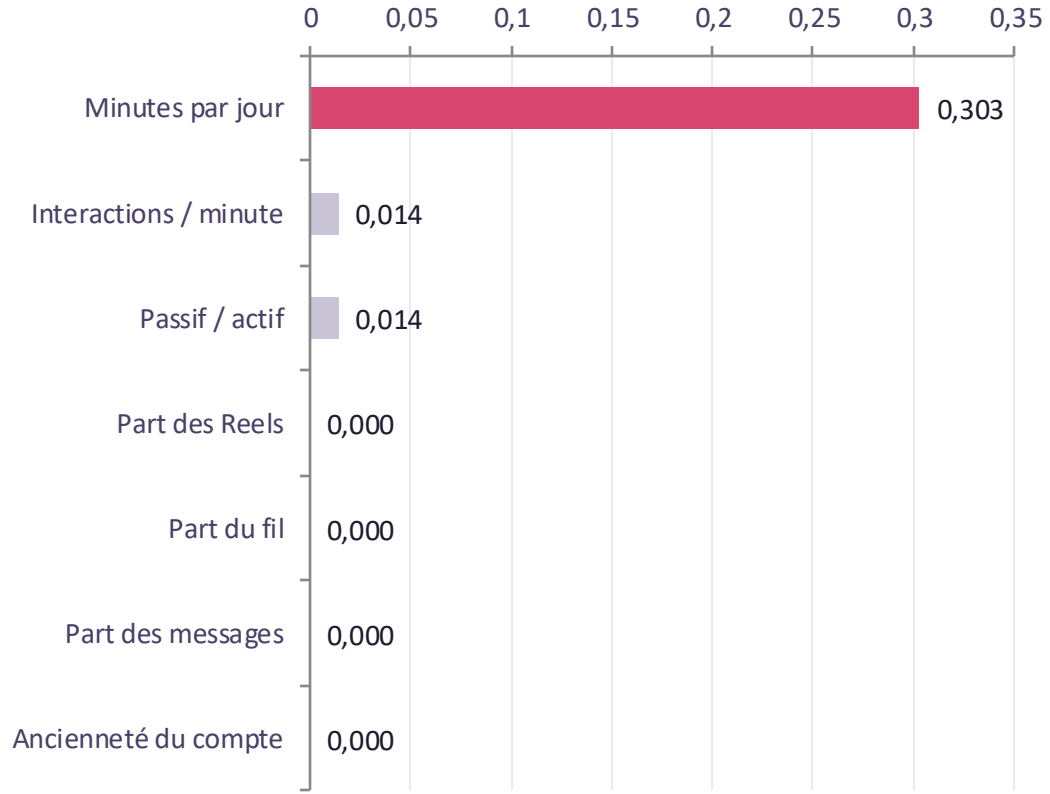
CONSTAT

Les autres variables d'usage n'ajoutent presque rien au temps passé

Temps seul contre toutes les variables (test 70/30)



Importance des variables (perte d'AUC si brouillée)

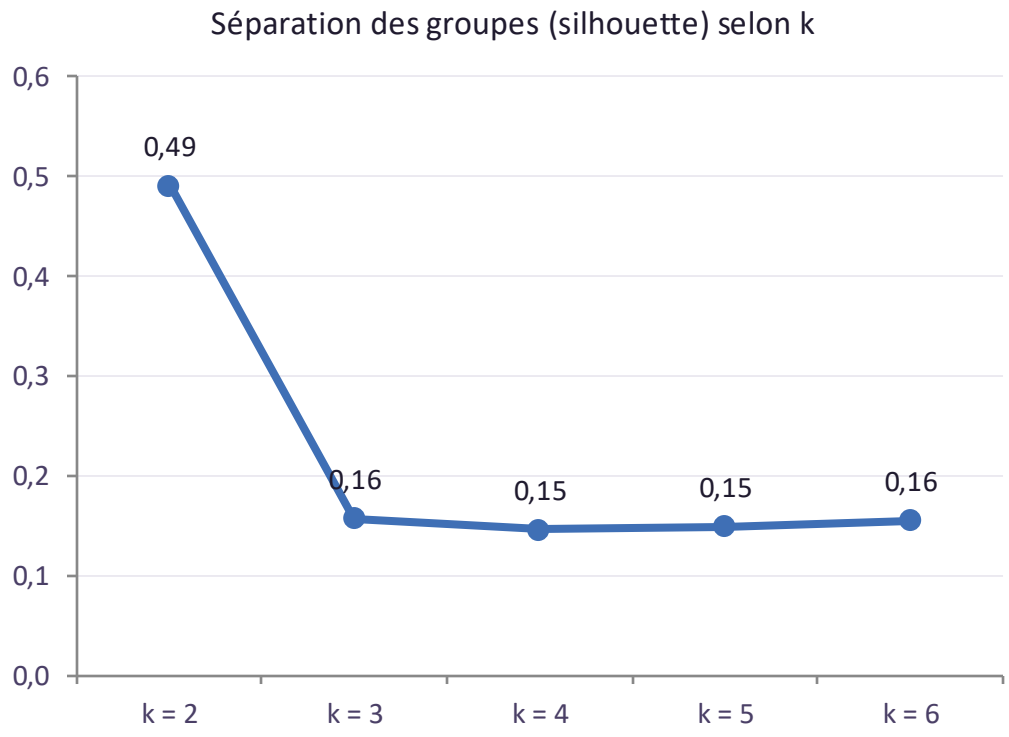


Le modèle sur le temps seul atteint déjà une AUC de 0,912 : il classe correctement 9 paires sur 10. Brouiller le temps fait perdre 0,303 d'AUC ; brouiller n'importe quelle autre variable, 0,014 au plus.

07

CONSTAT

Le clustering ne trouve pas de profils naturels au-delà de l'intensité



Groupe KMeans (k = 4)	Part	Min/jour	Stress
Groupe 1	34 %	202	21,2
Groupe 2	29 %	200	21,0
Groupe 3	30 %	202	21,3
Groupe 4 : usage minimal	7 %	6	4,1

0,333

stabilité sur deux moitiés (ARI) : les groupes changent d'un échantillon à l'autre

0,177

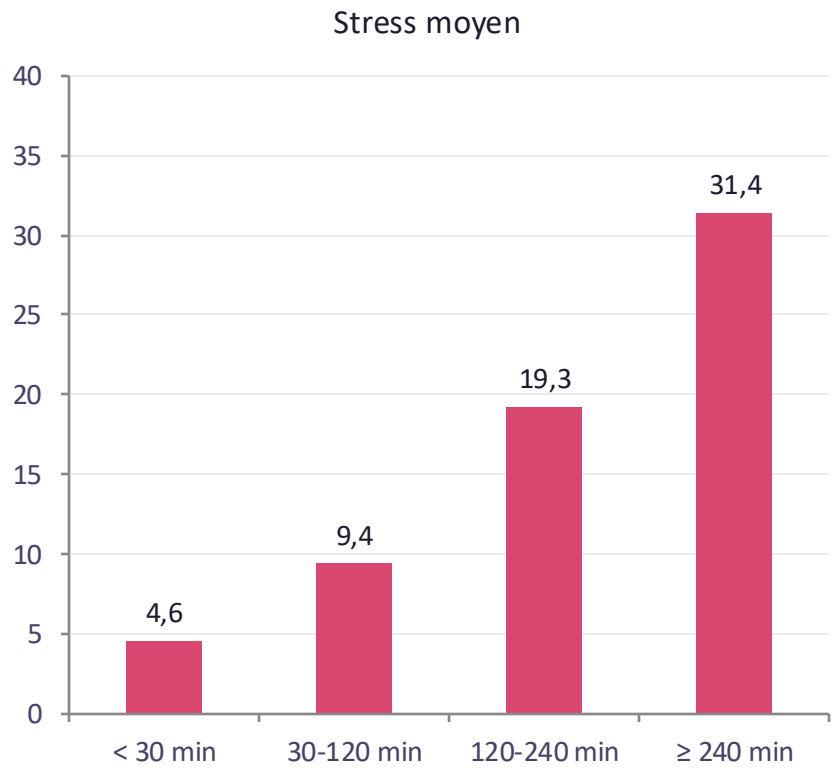
part du bien-être expliquée, contre 0,644 pour les seuils de temps

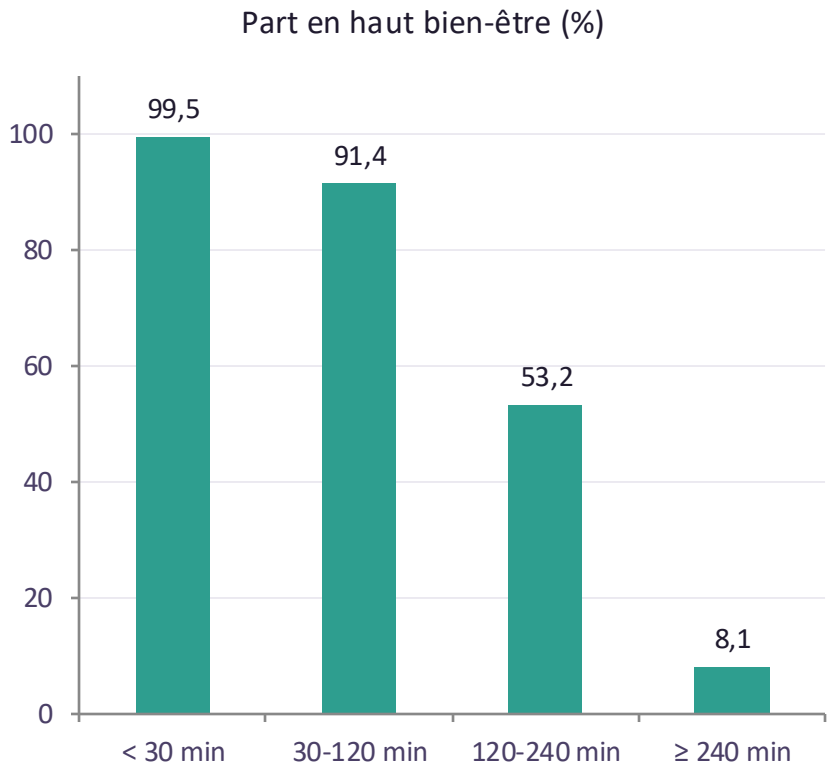
Seul découpage net : « usage minimal » contre « le reste ». Trois groupes sur quatre sont identiques.

08

NOTRE SEGMENTATION

quatre niveaux d'intensité, lisibles et stables





Segment	Part	Effectif
< 30 min	9 %	17 714
30-120 min	21 %	42 024
120-240 min	36 %	71 865
≥ 240 min	34 %	68 397

Stabilité : 1,00 par construction. Le plus petit segment compte 17 714 personnes : aucune cellule ne pose de problème de confidentialité.

Ce que la segmentation apporte en plus du temps passé : pas de prédiction supplémentaire, mais des seuils métier lisibles (30, 120, 240 min), assignables sans modèle et qui expliquent 64 % de la variance du bien-être.

09

NOTRE SEGMENTATION

Placer n'importe quel nouvel utilisateur : une règle, sans modèle

< 30 min

Usage très faible

30-120 min

Usage modéré

120-240 min

Usage élevé

≥ 240 min

Usage très élevé

minutes actives par jour : un seul champ, connu pour tous les utilisateurs

Exemple : profil fictif à 90 min/jour

→ segment « Usage modéré (30-120 min) »
→ probabilité estimée de haut bien-être : 0,89

Garanties

- Aucune donnée de santé en entrée
- Déterministe : même utilisateur, même segment
- Démonstration sur profil fictif, jamais sur une ligne réelle

10

RÉSULTAT

Cinq critères atteints, un seul partiellement : et c'est un résultat

Critère	Mesure	Résultat	Verdict
Assignable	règle sur les minutes actives	tout utilisateur	**Atteint**
Stable	seuils déterministes (KMeans : ARI 0,33)	1,00	**Atteint**
Distinct	taille du plus petit segment	17 714 utilisateurs	**Atteint**
Interprétable	nombre de variables	1 pour segmenter, 10 pour analyser	**Atteint**
Sûr juridiquement	santé en entrée, cellules < 50	aucune, aucune	**Atteint**
Incrémental	ΔAUC et ΔR^2 vs temps seul	+0,004 et +0,006	**Partiel**

Pourquoi « partiel » n'est pas un échec : le temps passé contient déjà l'essentiel de l'information. Ajouter des variables ou des clusters ne crée pas de signal qui n'existe pas dans les données.

LIMITES/CONDITIONS

11 Ce que nous n'affirmons pas, et à quelles conditions déployer

Limites

- **Pas de causalité :** données relevées à une seule date ; le stress peut aussi pousser à passer plus de temps sur l'appli.
- **Panel ≠ tous les utilisateurs :** le bien-être vient de volontaires d'une étude.
- **Réplique synthétique :** stress uniforme, sommeil sans lien, stress et bonheur indépendants sont des traces du générateur.
- **Score de bien-être :** un construit à poids égaux, pas une mesure clinique.

Protection des données (UE, Royaume-Uni)

- **Santé :** stress et bonheur relèvent de l'article 9 du RGPD ; jamais en entrée des segments.
- **Inférence :** le segment de temps révèle indirectement le stress (64 %) : base légale, finalité compatible et analyse d'impact obligatoires.
- **Mineurs :** 9,5 % des utilisateurs, et 12,4 % du segment ≥ 240 min : aucun ciblage fondé sur le bien-être.
- **Confidentialité :** aucune ligne individuelle affichée, aucune cellule de moins de 50 personnes.

Combien, plutôt que comment : nos recommandations

1

Retenir

Quatre segments par temps passé pour les fonctions de bien-être : rappels de pause, limites de temps choisies par l'utilisateur.

2

Refuser

Toute affirmation causale, tout ciblage fondé sur le bien-être ou visant les mineurs, toute lecture clinique du score.

3

Prochaine étape

Tester le style d'usage à temps passé égal (3 bandes × 2 styles) et mesurer l'effet réel des rappels de pause par expérimentation.

Merci. Nous prenons vos questions.

